

张迪

出生年月：2001.10


求职意向：大模型算法实习 | AI Agent

研发实习 | 多智能体方向实习

北京市海淀区

130-0817-7982

1319389508@qq.com



教育背景

2024.09~至今	北京航空航天大学	智能感知	GPA: 3.89/4 (1/170)
2020.09~2024.07	西南交通大学	测控技术与仪器	GPA: 3.80/4 (1/58)

项目经历

2026.05~2026.06 面向购买转化的个性化多轮导购 Agent

开发可记忆用户偏好的多轮电商导购应用，支持用户通过自然语言完成推荐、筛选、对比、详情追问、购物车管理与模拟结算，并持续调整后续推荐与购买建议，覆盖从需求理解到购买转化的完整流程。

技术栈 | Python、FastAPI、RAG、SSE、LLM API (豆包)、Kotlin、Jetpack Compose

- ◆ **设计分层 Agent 编排架构**：串联意图理解、RAG 检索、回复生成、事实校验与工具执行，并通过 SSE 向 Android 端渐进返回文本、商品卡片和业务状态；
- ◆ **构建混合 RAG 检索链路**：面向 **151 款商品**，融合结构化硬过滤、关键词匹配、BGE/Text2Vec 双路语义召回及 BGE-Reranker 重排，支持模糊和非标准需求下的商品匹配；
- ◆ **设计任务规划与多轮记忆机制**：以结构化任务计划拆解复合指令，结合对话状态管理与事件记忆解析第一款、“刚才那个”等跨轮指代，实现复合任务的连续执行；
- ◆ **构建分层个性化与隐私控制机制**：融合用户画像、对话证据和购物车关系，结合相似用户协同过滤与冷启动优化推荐，并支持全量、语义摘要和关闭三档隐私模式；
- ◆ **构建可信可控的 Agent 保障机制**：将大模型规划与确定性业务执行解耦，通过商品事实校验、本地降级及全链路监控降低幻觉与误操作风险，并以 **56 个端到端测试**验证核心场景。

科研经历

2025.10~2026.02 LLMODE: 面向结构化时空模态的 LLM 外部记忆注入框架设计

面向时空预测任务，解决**时空数据难接入 LLM、上下文长度受限、语义空间不对齐**等核心问题。

- ◆ 采用 Graph-aware Neural ODE 编码连续时间动态，通过 Perceiver Resampler 压缩固定预算 Token，并以门控交叉注意力注入 LLM 隐状态；
- ◆ Token 数量减少约 89%、推理延迟降低约 87%；在 NYCtaxi、NYCbike、NYCCrime 上较最佳基线 MSE 分别降低 29.7%、11.0%、18.4%；相关论文投稿 **IMWUT 2026 (CCF-A, 第 1 作者, 在投)**。

2026.02~2026.05 MasFACT: 面向 LLM 多智能体的持续学习与拓扑迁移算法

针对 LLM-based 多智能体系统在**持续学习**场景下存在的**历史协作拓扑遗忘、跨任务 Agent 空间不对齐、少样本新任务适应易过拟合**等问题，研究基于历史拓扑迁移与保守后验适应的动态通信图生成方法。

- ◆ 设计“拓扑构建—跨任务对齐检索—保守残差更新”流程，基于 FGW 最优传输完成 Agent 语义与通信图结构对齐，并以 PAC-Bayes 和 KL 稀疏正则约束拓扑漂移；
- ◆ 在 17 个推理数据集、12 类场景中，平均准确率提升 9.3%、平均遗忘率降低 69.4%；相关论文投稿 **NeurIPS 2026 (第 3 作者, 在投)**。

技术栈

编程框架：Python、PyTorch、FastAPI、Linux、Git

算法方向：LLM、AI Agent、多智能体系统、持续学习、时空预测、Neural ODE

语言能力：CET-6 (590)、CET-4 (650)